# 자연어처리(딥러닝) 연구 논문 조사

박철원(Park Cheolwon, 2024270616)
2025. 11. 19. (수) 제출

### 1.1 대상 논문

A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, “Improving Language Understanding by Generative Pre-Training,” OpenAI, 2018.

### 1.2 논문 요약 및 정리

#### 1.2.1 개요 및 배경

본 논문은 자연어 이해(NLU)를 위한 새로운 반지도 학습(Semi-supervised) 프레임워크를 제안한다. 자연어 처리(NLP) 분야는 레이블이 지정된(labeled) 데이터가 부족한 반면, 레이블이 없는(unlabeled) 방대한 텍스트 코퍼스는 풍부하다. 이 문제를 해결하기 위해, 본 논문은 아래의 2단계 접근 방식을 제시한다.

(1) 다양한 비지도 텍스트 코퍼스에서 Generative Pre-Training(생성적 사전학습)을 통해 Language Model(언어 모델)을 학습시킨다.
(2) 각 특정 작업(task)에 맞춰 레이블된 데이터로 Discriminative Fine-Tuning(판별적 미세조정)을 수행한다.

이 방식의 핵심은 파인튜닝 시 task-aware input transformation(과제 인지적 입력 변환)을 사용하여, 모델 아키텍처 변경을 최소화하면서도 효과적인 정보 전이를 달성하는 것이다. 실험을 통해 이 task-agnostic(범용적) 모델은 12개 NLU 과제 중 9개에서 SOTA(State-of-the-Art)를 달성했으며, 특히 상식 추론(Stories Cloze Test)에서 8.9%, 질문 응답(RACE)에서 5.7%, 텍스트 함의(MultiNLI)에서 1.5%의 큰 폭의 성능 향상을 보였다.

#### 1.2.2 기존 연구의 한계

기존 딥러닝 방식은 수동으로 레이블이 지정된 대규모 데이터가 필요하며, 이로 인해 레이블된 자원이 부족한 도메인에서는 적용이 제한적이다. 사전학습된 워드 임베딩(word embeddings)을 사용하는 것이 표준이 되었지만, 이는 주로 단어 수준의 정보만 전달한다는 한계가 있다. 문장 수준 이상의 의미를 비지도 방식으로 학습하려는 시도는 있었으나, 어떤 최적화 목표(e.g. 언어 모델링, 기계 번역 등)가 효과적인지, 그리고 학습된 표현을 어떻게 대상 과제에 전이하는 것이 가장 효과적인지에 대한 명확한 합의가 없었다.

#### 1.2.3 Generative Pre-Training(GPT) 프레임워크

본 논문은 2단계 학습 절차를 사용한다.

**(a) 1단계: 비지도 사전학습(Unsupervised Pre-Training)**

**목표:** 레이블이 없는 토큰 코퍼스 $u = \{u_1, \cdots, u_n\}$에 대해, 표준 언어 모델링 목표를 사용하여 다음 우도(likelihood)를 최대화한다.

$$L_1(u) = \sum_i \log P(u_i | u_{i-k}, \cdots, u_{i-1}; \Theta)$$

($k$는 컨텍스트 윈도우 크기, $P$는 파라미터 $\Theta$를 가진 신경망으로 모델링된 조건부 확률)

**모델 아키텍처:** 언어 모델을 위해 멀티 레이어 Transformer Decoder를 사용한다. 이 모델은 입력 컨텍스트 토큰에 대해 Multi-headed Self-attention을 적용하고, Position-wise Feedforward 레이어를 통과시켜 타겟 토큰에 대한 출력 분포를 생성한다.

$$h_0 = UW_e + W_p$$
$$h_l = \text{transformer_block}(h_{l-1}) \forall i \in [1, n]$$
$$P(u) = \text{softmax}(h_n W_e^T)$$

($U = (u_{-k}, \cdots, u_{-1})$는 토큰의 컨텍스트 벡터, $n$은 레이어 수,
$W_e$는 토큰 임베딩 행렬, $W_p$는 위치 임베딩 행렬)

(b) **2단계: 지도 파인튜닝**(Supervised Fine-Tuning)

**목표:** 사전학습된 모델 파라미터를 특정 지도 학습 과제에 맞게 조정한다. 레이블된 데이터셋 $C$는 입력 토큰 시퀀스 $x^1, \cdots, x^m$과 레이블 $y$의 쌍으로 구성된다.

**구현:** 입력을 사전학습된 모델에 통과시켜 마지막 Transformer 블록의 활성화 $h_l^m$을 얻고, 이를 파라미터 $W_y$를 가진 추가된 선형 출력 레이어에 입력하여 $y$를 예측한다.

$$P(y|x^1, \cdots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(C) = \sum_{(x,y)} \log P(y|x^1, \cdots, x^m)$$

(c) **보조 학습 목표**(Auxiliary Objective)

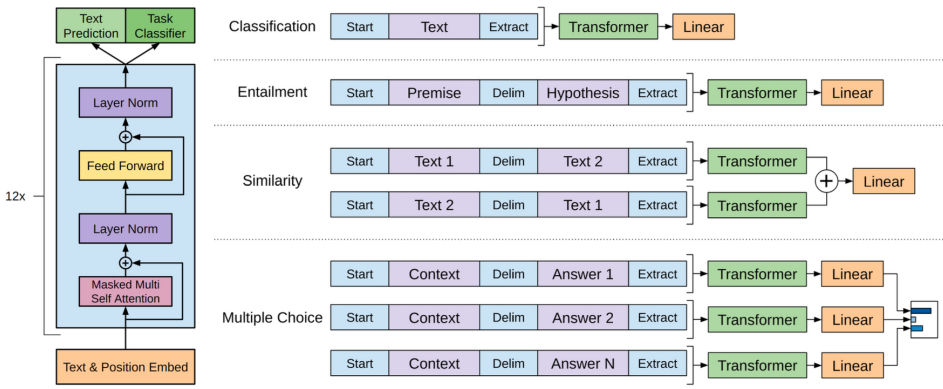
파인튜닝 시, $L_2$(지도 학습 목표)에 $L_1$(언어 모델링 목표)을 보조 목적 함수로 추가하는 것이 도움이 된다는 것을 발견하였다.

**이점:** 지도 모델의 일반화 성능 향상, 수렴 가속화

$$L_3(C) = L_2(C) + \lambda \times L_1(C) \quad (\lambda\text{는 가중치})$$

### 1.2.4 과제별 입력 변환(Task-specific Input Transformations)

텍스트 분류와 같은 단일 문장 과제는 직접 파인튜닝할 수 있으나, 텍스트 함의(문장 쌍)나 QA(문서, 질문, 답변의 3중 구조)와 같은 구조화된 입력은 사전학습 모델이 학습한 연속 텍스트 시퀀스와 형식이 다르다. 따라서, 과제별로 아키텍처를 새로 설계하는 대신, 구조화된 입력을 순서가 있는 단일 시퀀스로 변환하는 traversal-style 접근 방식을 사용한다.



**텍스트 함의(Entailment):** 전제 $p$와 가설 $h$ 사이에 구분자 토큰($)을 삽입한다.

**유사도(Similarity):** 비교할 두 문장(Text1, Text2)은 순서가 없으므로, `Text1; $; Text2` 와 `Text2; $; Text1` 두 가지 순서의 시퀀스를 각각 독립적으로 처리한다. 두 시퀀스에서 나온 최종 $h_l^m$ 표현을 요소별로 더한(element-wise add) 후 선형 레이어에 입력한다.

**질문 응답(Question Answering):** 문맥 문서 $z$, 질문 $q$, 가능한 답변 집합 $a_k$가 주어지면, 각 가능한 답변 $a_k$에 대해 `z; q; $; a_k` 형태의 시퀀스를 생성한다. 각 시퀀스를 모델로 독립 처리한 후, Softmax 레이어를 통해 정규화하여 가능한 답변에 대한 출력 분포를 얻는다.

### 1.2.5 모델 설정

(a) Setup

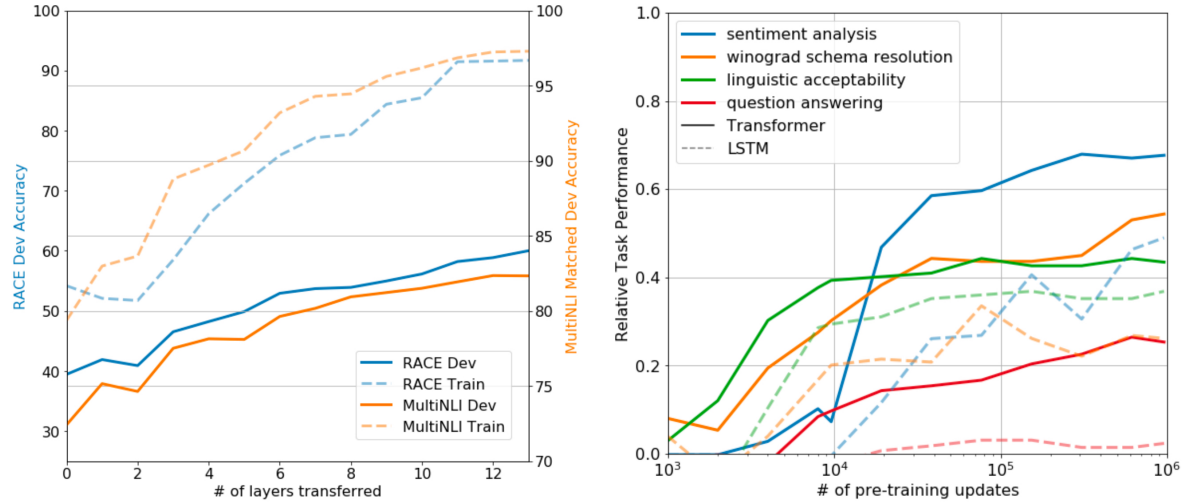
| | |
|---|---|
| **사전학습 데이터** | BooksCorpus 데이터셋을 사용하였으며, 7,000권 이상의 미출간 도서로 구성되어 있다. 긴 범위의 연속된 텍스트(long stretches of contiguous text)를 포함하고 있어 장기 의존성(long-range information) 학습에 유리하다. |
| **텍스트 전처리** | ftfy 라이브러리를 사용하여 raw text를 정리하고, 구두점 및 공백을 표준화하였다.<br>토크나이저로는 spaCy를 사용하였다. |

(b) Model Specifications

| | |
|---|---|
| **아키텍처** | 원본 Transformer를 따르며, 12-layer decoder-only transformer를 학습시킨다. |
| **어텐션** | Masked self-attention heads(768차원 state, 12 어텐션 헤드)를 사용한다. |
| **Feed-Forward** | Position-wise feed-forward 네트워크는 3072차원의 내부 state를 사용한다. |
| **활성화 함수** | Gaussian Error Linear Unit(GELU)을 사용한다. |
| **위치 임베딩** | 원본 논문의 sinusoidal 버전 대신 learned position embeddings를 사용한다. |
| **어휘** | 40,000 merge의 Byte Pair Encoding(BPE) 어휘를 사용한다. |

(c) Fine-tuning Details

| | |
|---|---|
| **학습 단위** | 512개 토큰으로 구성된 무작위 샘플링된 연속 시퀀스를 미니배치 크기 64로, 100 epoch 동안 학습한다. |
| **옵티마이저** | Adam optimization scheme을 사용하며, max learning rate는 $2.5e^{-4}$로 설정한다. |
| **학습률 스케줄** | 처음 2000 업데이트 동안 0에서부터 선형적으로 증가시킨 후, 코사인 스케줄을 사용해 0으로 서서히 감소시킨다(annealed). |
| **초기화** | 모델 전체에 layernorm이 광범위하게 사용되었으므로, N(0, 0.02)의 단순한 가중치 초기화만 적용한다. |
| **정규화** | Residual, embedding, attention dropouts는 0.1의 비율로 적용한다.<br>L2 정규화를 사용하며, bias와 gain 가중치를 제외한 모든 가중치에 $w$=0.01을 적용한다. |




### 1.2.6 핵심 분석 및 결론

논문의 Ablation Studies(제거 연구)는 이 접근법의 핵심 요소를 명확히 증명했다.

첫째, 사전학습의 효과는 절대적이었다. 사전학습 없이 Transformer 아키텍처를 바로 지도 학습시킨 결과, 12개 과제 전체에서 평균 14.8%라는 큰 폭의 성능 저하가 발생했다.

둘째, Transformer와 LSTM 비교에서는 동일한 프레임워크에서 Transformer 대신 2048 유닛의 단일 레이어 LSTM으로 교체하자 평균 5.6점의 성능 하락이 나타났다. 이는 Transformer의 구조적 이점(inductive bias)이 전이 학습에 더 유리함을 시사한다.

셋째, 보조 목표의 효과는 데이터셋 크기에 따라 달랐는데, NLI나 QQP 같은 대규모 데이터셋에서는 성능 향상에 도움이 되었으나 소규모 데이터셋에서는 효과가 미미했다.

또한 전이되는 레이어 수를 분석한 결과, 사전학습된 모델의 레이어를 0개(임베딩만 전이)부터 12개(전체 전이)까지 늘려갈수록 MultiNLI와 RACE 과제 모두에서 성능이 꾸준히 향상되었다. 이는 사전학습된 모델의 모든 레이어가 대상 과제 해결에 유용한 기능을 포함하고 있음을 강력하게 보여준다.

결론적으로, 이 논문은 생성적 사전학습과 판별적 미세조정을 결합한 단일 과제 불가지론적(task-agnostic) 모델 프레임워크를 성공적으로 제안했다. 장기 의존성이 풍부한 다양한 코퍼스(BooksCorpus)에서의 사전학습을 통해, Transformer 모델이 상당한 수준의 세계 지식과 장거리 의존성 처리 능력을 획득하고, 이를 다양한 NLU 과제로 효과적으로 전이할 수 있음을 입증한 연구라고 할 수 있다.